

Matriz de Costos

Ecosistema de Automatizacion IA — AlmaAlquiler | Trabajo Final — Coderhouse Automatizacion con IA |
Proveedor elegido: Anthropic (Claude) — Modelo: **Claude Haiku 4.5**

1. Supuestos de la estimacion

No se cuenta con datos historicos reales de volumen de consultas, por lo que se estiman tres escenarios (bajo/medio/alto) a criterio, representativos de un alquiler temporario individual en temporada baja, media y alta.

Parametro	Valor estimado	Nota
Consultas / mes (bajo)	20	temporada baja
Consultas / mes (medio)	40	temporada media
Consultas / mes (alto)	80	temporada alta
Tokens de entrada / consulta	~600	prompt de sistema + mensaje del huesped
Tokens de salida / consulta	~250	JSON estructurado (nombre, perfil, prioridad, resumen, respuesta)

2. Tarifas oficiales (Anthropic, claude.com/pricing)

Modelo	Input (por MTok)	Output (por MTok)
Claude Haiku 4.5	\$1.00	\$5.00
Claude Sonnet 5	\$2.00	\$10.00
Claude Opus 5	\$5.00	\$25.00

3. Costo por consulta individual

Modelo	Costo input	Costo output	Costo total / consulta
Claude Haiku 4.5	\$0.00060	\$0.00125	\$0.00185
Claude Sonnet 5	\$0.00120	\$0.00250	\$0.00370
Claude Opus 5	\$0.00300	\$0.00625	\$0.00925

4. Proyeccion de costo mensual por escenario

Escenario	Consultas / mes	Haiku 4.5	Sonnet 5	Opus 5
Bajo	20	\$0.037	\$0.074	\$0.185
Medio	40	\$0.074	\$0.148	\$0.370
Alto	80	\$0.148	\$0.296	\$0.740

5. Ahorro de Haiku 4.5 frente a las alternativas

Comparacion	Ahorro
Haiku 4.5 vs. Sonnet 5	50% mas barato
Haiku 4.5 vs. Opus 5	80% mas barato

6. Justificacion de la eleccion de modelo

La tarea que resuelve el nodo “Anthropic Chat Model” es **clasificacion estructurada de bajo razonamiento**: extraer nombre, perfil de estadia, prioridad y generar una respuesta sugerida a partir de un mensaje corto de consulta. No requiere razonamiento multi-paso, uso extendido de herramientas ni contexto largo — el perfil de tarea donde Sonnet u Opus no aportan mejora de calidad proporcional a su costo adicional.

Con el volumen esperado para un alquiler temporario individual (decenas de consultas por mes, no miles), el costo absoluto es marginal en cualquiera de los tres modelos — pero elegir Haiku 4.5 deja margen para escalar el flujo (mas unidades de negocio, mas canales) sin que el costo por token se vuelva un factor limitante, cumpliendo el criterio de optimizacion de costos de la consigna.

7. Optimizaciones adicionales disponibles (no implementadas en esta entrega)

Optimizacion	Ahorro potencial	Aplicabilidad al flujo
Prompt caching (system prompt fijo)	Hasta 90% sobre el input	El system prompt de clasificacion es estatico entre ejecuciones
Batch API	50% en input y output	El flujo requiere respuesta en tiempo real por consulta

Tarifas verificadas en claude.com/pricing, consultado el 10/09/2026. Sujetas a cambio segun lo publicado por Anthropic.